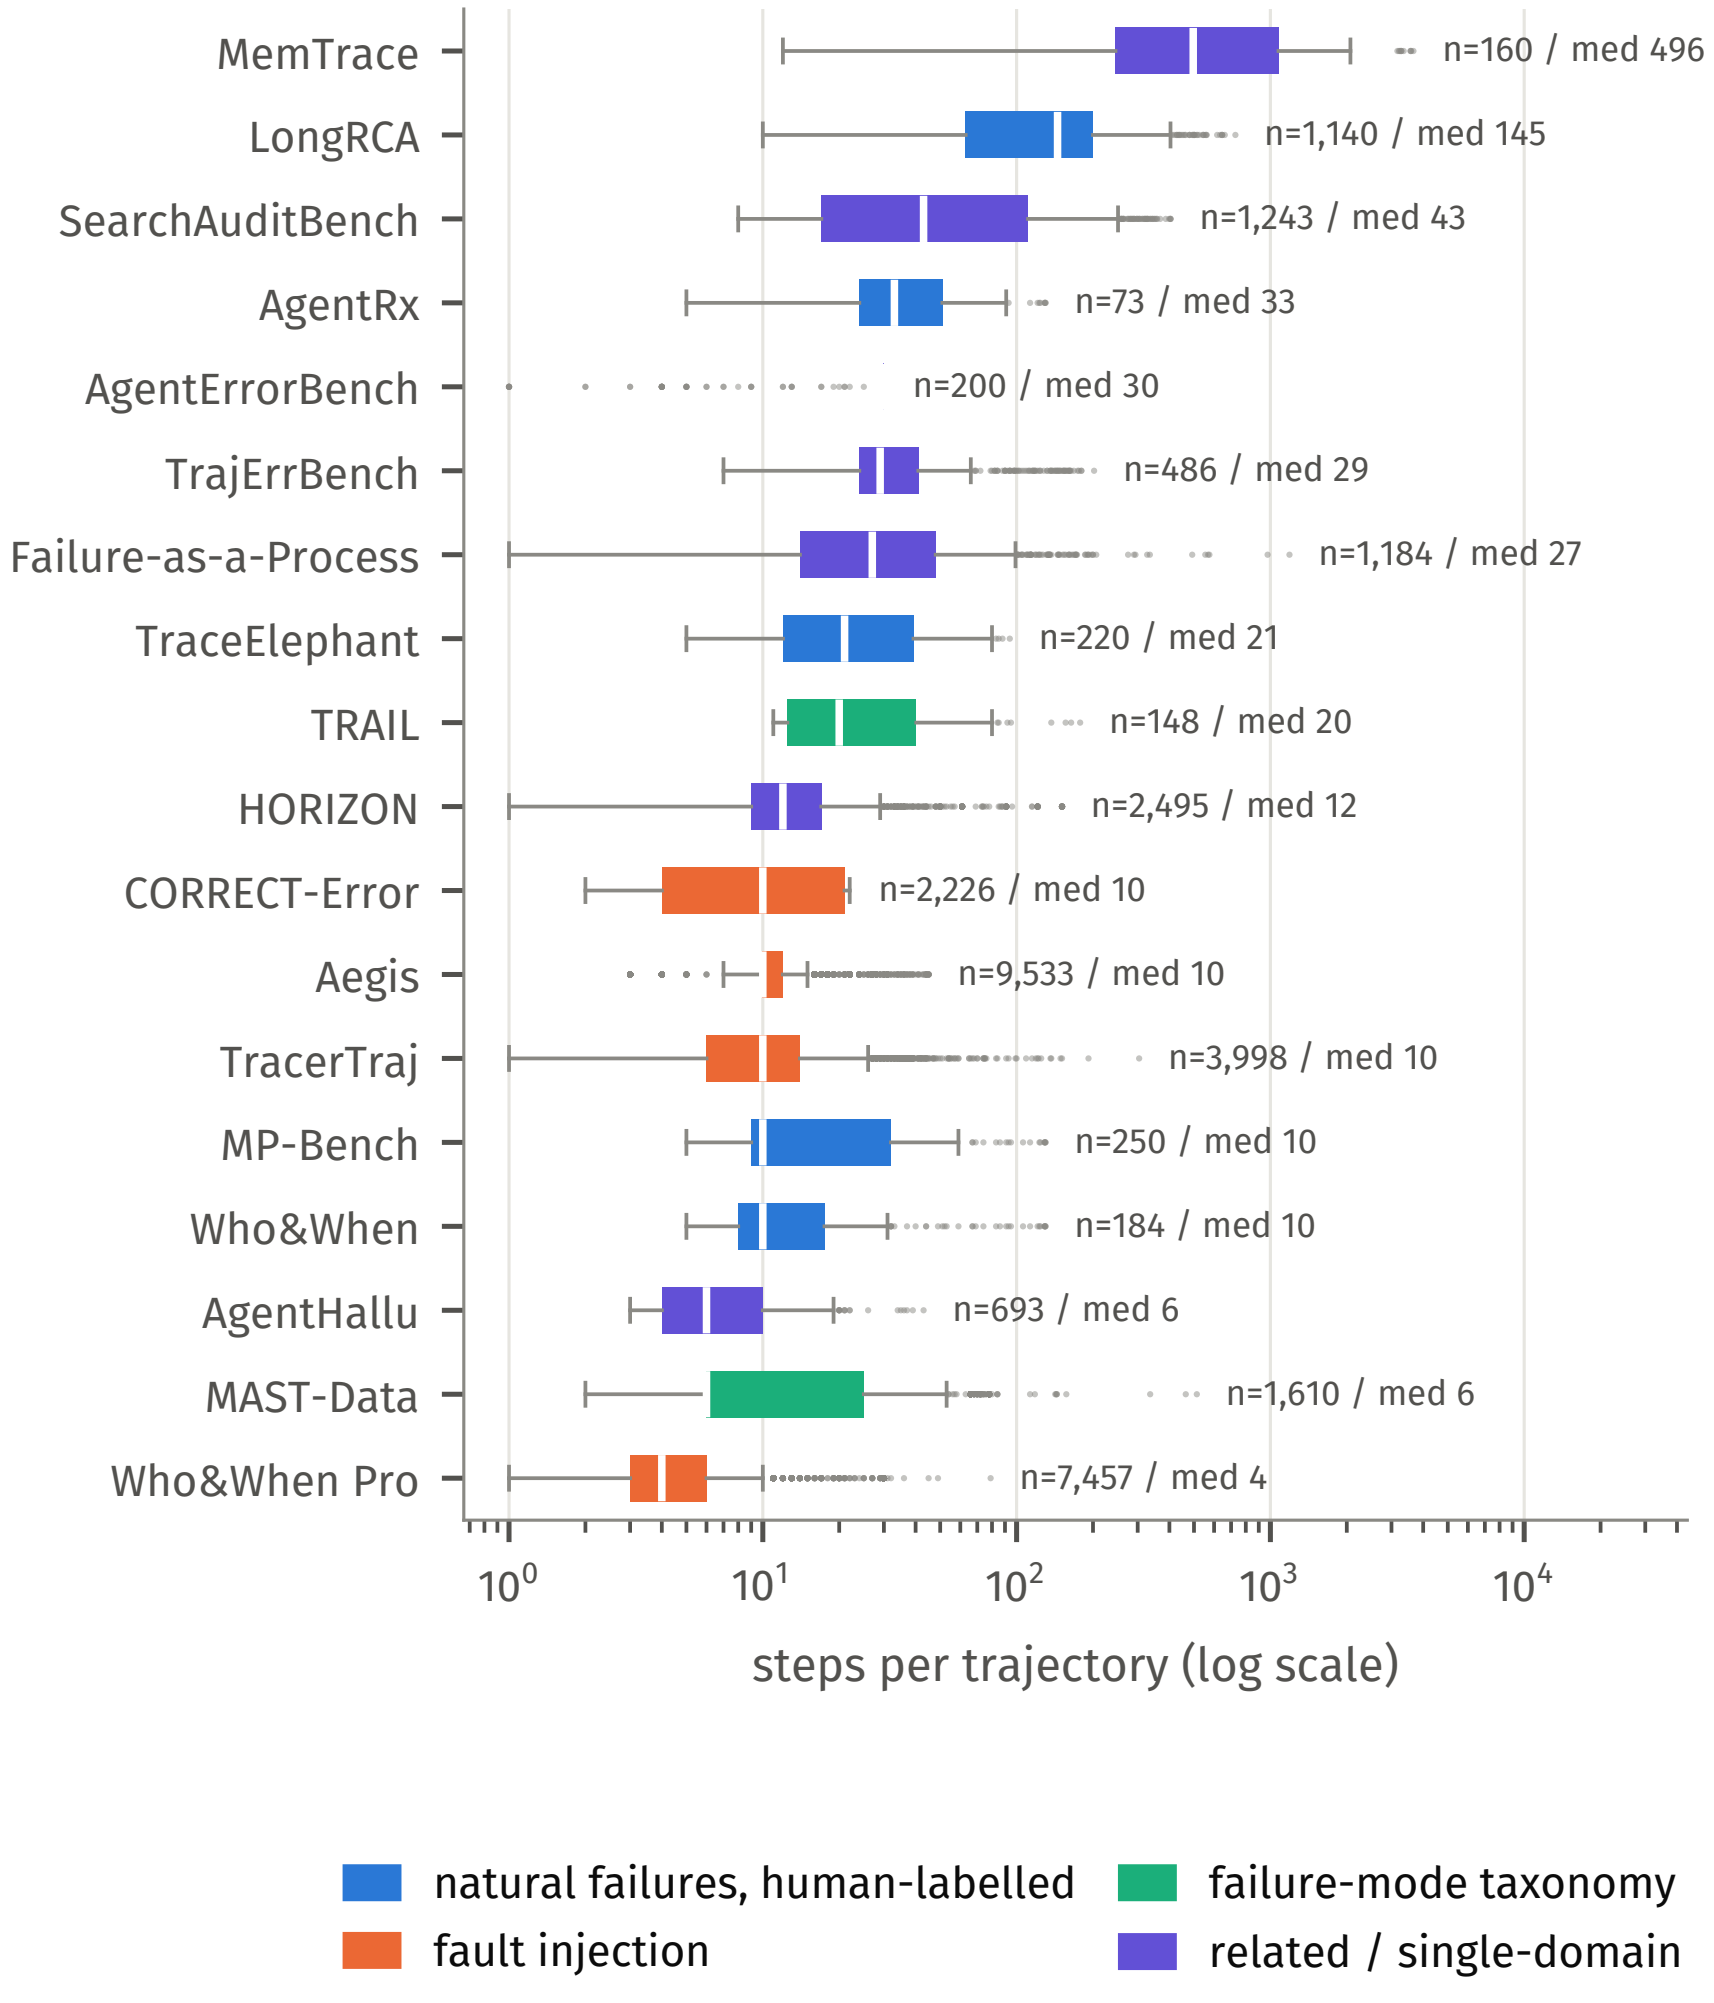
MemTrace
LongRCA
SearchAuditBench
AgentRx
AgentErrorBench
TrajErrBench
Failure-as-a-Process
TraceElephant
TRAIL
HORIZON
CORRECT-Error
Aegis
TracerTraj
MP-Bench
Who&When
AgentHallu
MAST-Data
Who&When Pro
n=160 / med 496
n=1,140 / med 145
n=1,243 / med 43
n=73 / med 33
n=200 / med 30
n=486 / med 29
n=1,184 / med 27
n=220 / med 21
n=148 / med 20
n=2,495 / med 12
n=2,226 / med 10
n=9,533 / med 10
n=3,998 / med 10
n=250 / med 10
n=184 / med 10
n=693 / med 6
n=1,610 / med 6
n=7,457 / med 4
$10^0$
$10^1$
$10^2$
$10^3$
$10^4$
steps per trajectory (log scale)
natural failures, human-labelled
fault injection
failure-mode taxonomy
related / single-domain